Relatório da entrega 1: Análise Exploratória e Diagnóstico dos Dados (EDA)

Equipe:
Allanis Beatriz Oliveira Maia de Lima - aboml@cin.ufpe.br
Amanda Pereira Muniz de Oliveira - apmo@cin.ufpe.br
João Victor Alexandre Justino da Silva - jvajs@cin.ufpe.br
Millena Ferreira Marçal das Neves - mfmn@cin.ufpe.br
Nelson de Barros Sales Neto - nbsn@cin.ufpe.br

1. Introdução e descrição do dataset

O projeto tem como objetivo o desenvolvimento de um modelo preditivo utilizando o algoritmo k-Nearest Neighbors (kNN), com foco na previsão da gravidade de ocorrências de trânsito. Para isso, foi selecionado o dataset "Ocorrências de Acidentes de Trânsito - 2024", disponibilizado pela Prefeitura do Recife.

A escolha desse conjunto de dados se justifica pela sua riqueza de informações, contemplando diferentes aspectos relacionados aos acidentes, como localização geográfica, características da via, tipos de veículos envolvidos e número de vítimas. Esses fatores são relevantes para a construção de um modelo capaz de identificar padrões e auxiliar na previsão da gravidade dos acidentes.

O dataset possui **5315 observações (linhas)** e **37 atributos (colunas)**, incluindo variáveis:

- **Categóricas (textuais):** bairro, natureza, condição da via, entre outras;
- **Numéricas:** quantidade de veículos envolvidos (auto, moto, ciclomotor, etc.) e número de vítimas;
- **Temporais:** data e hora da ocorrência.

A variável alvo (Target) definida para o modelo é a coluna `natureza`, que representa a gravidade do acidente, com categorias principais como COM VÍTIMA, SEM VÍTIMA e VÍTIMA FATAL.

2. Qualidade e diagnóstico dos dados

A etapa de diagnóstico foi realizada utilizando métodos como `.info()`.`isnull()`.`sum()` e análise de valores únicos, permitindo identificar problemas estruturais e inconsistências no dataset.

2.1 Valores ausentes e completude dos dados

Inicialmente, verificou-se que não há registros duplicados no conjunto de dados, o que indica uma boa consistência nesse aspecto.

Por outro lado, foram identificadas 12 colunas completamente vazias (100% de valores nulos), como *situacao_placa*, *condicao_via* e *sinalizacao*. Essas variáveis não contribuem com informação útil e, portanto, sua remoção será considerada na etapa de pré-processamento.

Além disso, algumas colunas apresentam alta taxa de valores ausentes, como *num_semaforo* e *detalhe_endereco_acidente*. Esse padrão sugere que essas informações não são coletadas de forma consistente, o que pode comprometer sua utilização no modelo.

2.2 Tipagem de dados e problemas de formatação

Um ponto relevante identificado foi a inconsistência na tipagem de variáveis numéricas. O dataset utiliza o padrão brasileiro de formatação, no qual a vírgula é empregada como separador decimal. Isso fez com que colunas quantitativas fossem inicialmente interpretadas como texto (*object*).

Esse problema foi resolvido diretamente na etapa de importação dos dados, utilizando o parâmetro `decimal=','` do Pandas. Com isso, variáveis como quantidade de veículos (auto, moto...) e número de vítimas passaram a ser corretamente reconhecidas como numéricas (float64), permitindo a realização de análises estatísticas adequadas.

2.3 Inconsistências em variáveis categóricas

A análise da variável alvo (natureza) revelou a presença de categorias que não representam diretamente a gravidade do acidente, como "APOIO" e "ENTRADA E SAÍDA".

Essas categorias podem introduzir ruído no modelo, pois não seguem o mesmo critério das demais classes. Dessa forma, será necessário tratá-las, seja por remoção ou reclassificação, para garantir maior coerência na variável alvo.

2.4 Inconsistências cronológicas

Durante a inspeção das últimas linhas do dataset (`.tail()`), identificou-se uma grave inconsistência cronológica na coluna `data`. Embora o conjunto de dados seja estritamente referente ao ano de 2024, existem registros preenchidos com datas no futuro (como '2025-12-31'). Isso indica falhas de digitação na origem ou preenchimentos automáticos incorretos pelo sistema gerador dos dados, exigindo filtragem temporal na próxima etapa.

3. Análise exploratória e principais insights

A análise exploratória foi conduzida por meio de visualizações gráficas e estatísticas descritivas (método `.describe()`), permitindo uma melhor compreensão do comportamento dos dados.

3.1 Desbalanceamento da variável alvo

O gráfico de contagem da variável natureza evidenciou um forte desbalanceamento entre as classes. A maior parte dos registros concentra-se nas categorias *COM VÍTIMA* e *SEM*

VÍTIMA, enquanto a categoria *VÍTIMA FATAL* representa uma parcela muito pequena do dataset.

Figura 1: Distribuição de frequência da variável alvo ('natureza'), evidenciando o forte desbalanceamento das classes.

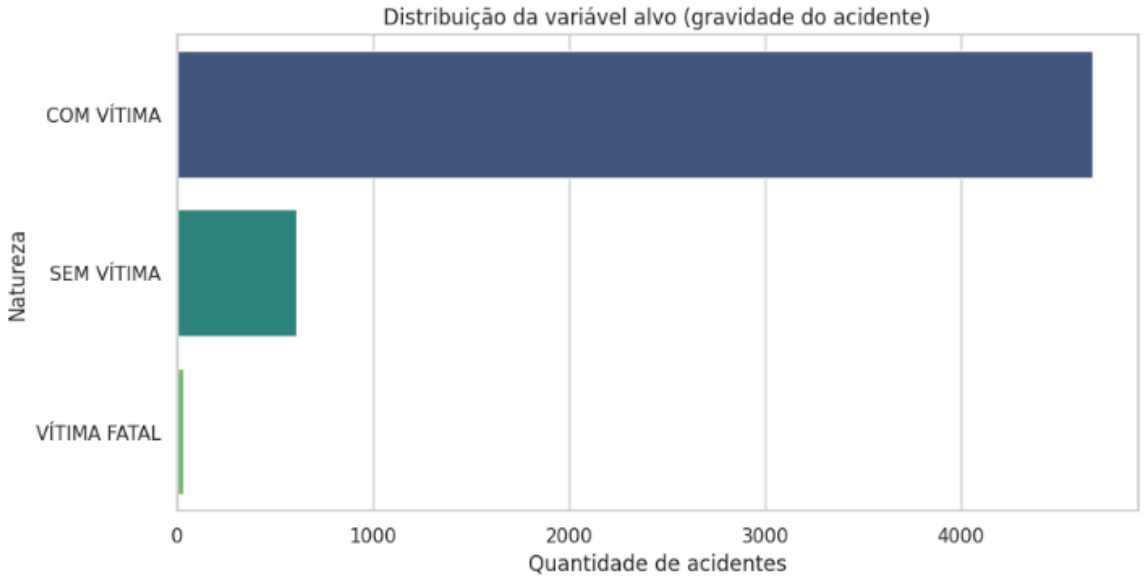

Figura 2: Distribuição de frequência da variável 'tipo' (tipo de acidente), evidenciando a forte concentração das ocorrências nas categorias genéricas de 'Colisão' e 'Colisão lateral'.

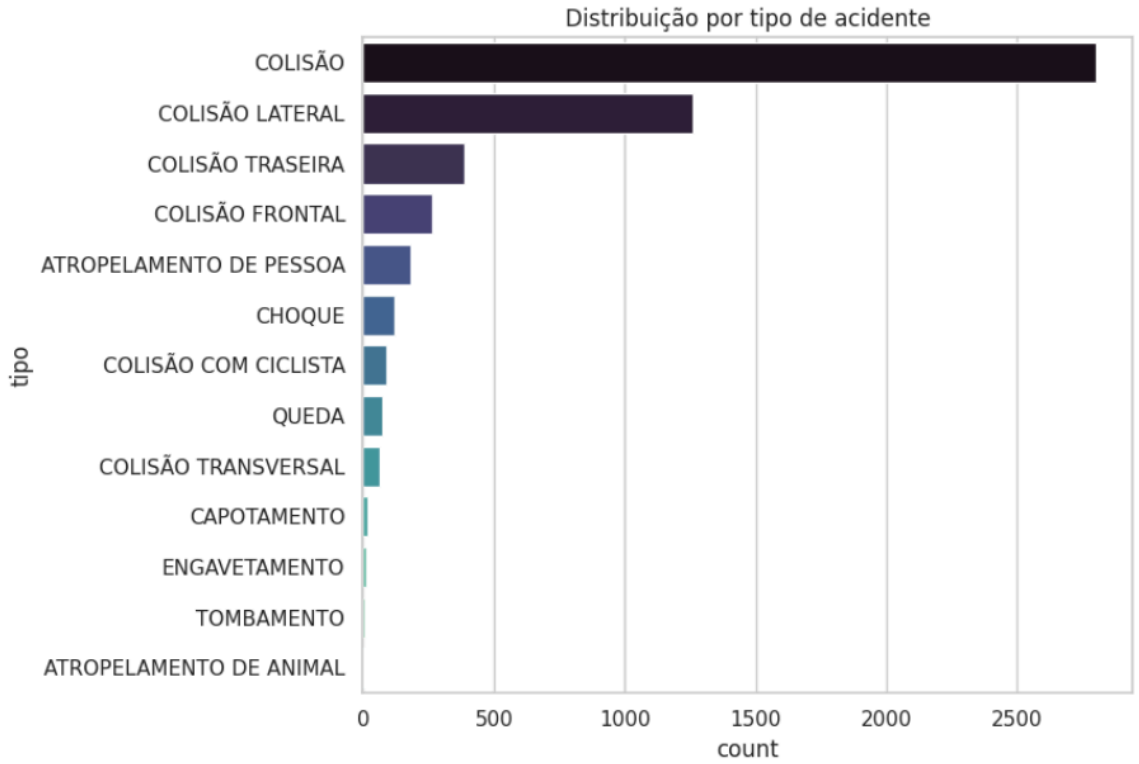

Esse cenário é relevante, pois o algoritmo kNN tende a favorecer classes majoritárias, podendo comprometer a capacidade do modelo de identificar corretamente eventos raros, como acidentes fatais. Dessa forma, será necessário aplicar técnicas de balanceamento de dados nas etapas posteriores.

3.2 Estatísticas descritivas e identificação de outliers

A utilização do método `.describe()` permitiu analisar métricas como média, mediana, desvio padrão, valores mínimos e máximos.

Observou-se que, em algumas variáveis, a média é significativamente maior que a mediana, indicando a presença de valores extremos que distorcem a distribuição dos dados. Esse comportamento é típico em cenários onde poucos registros apresentam valores muito elevados.

Além disso, os valores máximos identificados, como 4 veículos e 12 vítimas em um único acidente, sugerem a presença de outliers, já que a maioria dos acidentes envolve poucos veículos e vítimas.

Figura 3: Boxplot das variáveis numéricas, evidenciando valores extremos (outliers) que puxam as médias para cima.

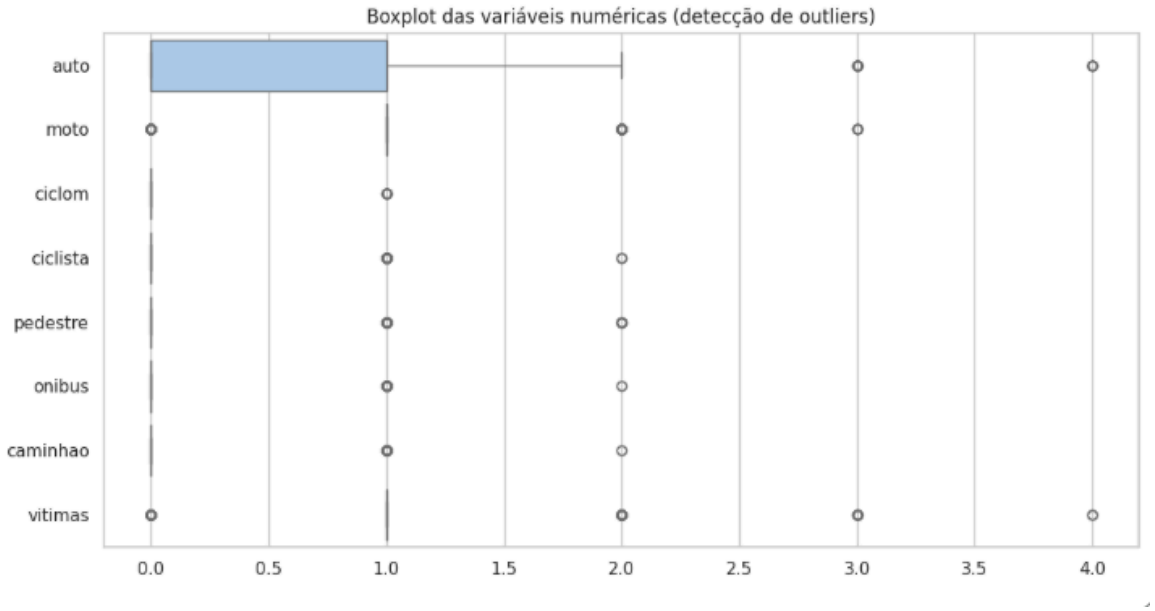

Esses valores atípicos podem impactar negativamente o desempenho do modelo, especialmente no caso do kNN, que depende da distância entre os pontos. Portanto, será necessário tratar esses casos na etapa de pré-processamento.

3.3 Distribuição das variáveis numéricas (histogramas)

Para aprofundar o entendimento sobre a natureza das variáveis quantitativas (quantidade de veículos envolvidos e número de vítimas), procedeu-se com a plotagem de seus respectivos histogramas.

A análise visual permitiu confirmar a natureza dessas variáveis: trata-se estritamente de dados numéricos discretos (representando contagens inteiras, sem valores fracionários). Além disso, os histogramas evidenciaram que nenhuma dessas variáveis segue uma Distribuição normal.

Figura 4: Histogramas das variáveis numéricas evidenciando a assimetria à direita e a natureza discreta dos dados.

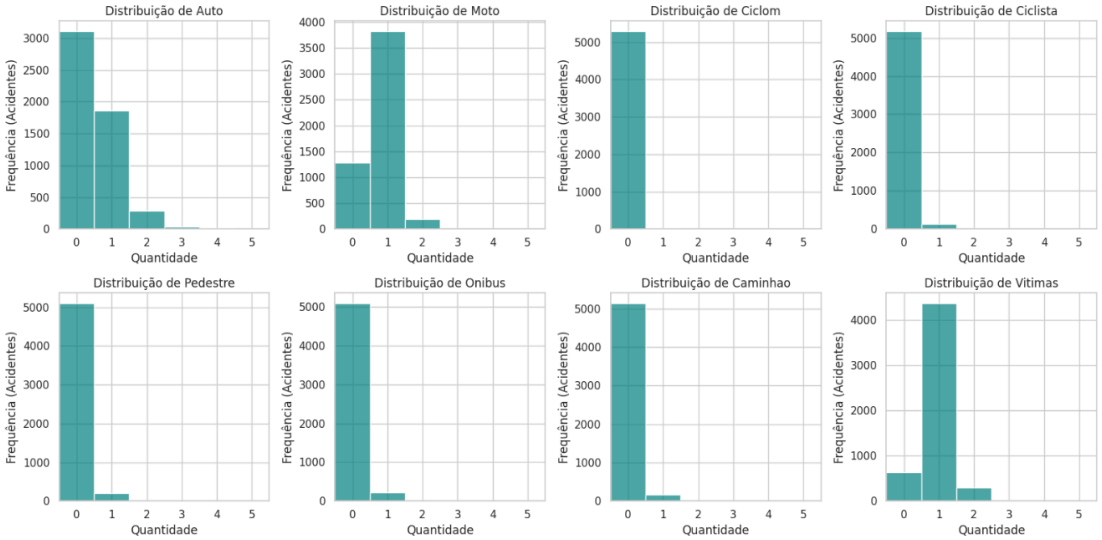

Todas as distribuições apresentam uma fortíssima assimetria à direita (positive skew). Isso significa que a esmagadora maioria dos acidentes (a moda) concentra-se em 0 ou 1 veículo específico/vítima, com a frequência decaindo drasticamente à medida que o número aumenta. Essa constatação é vital para a Entrega 2, pois distribuições altamente assimétricas indicam que algoritmos sensíveis a distâncias, como o kNN, exigirão que essas features sejam rigorosamente padronizadas (StandardScaler ou MinMaxScaler) para que valores maiores não dominem o cálculo espacial.

3.4 Padrões temporais dos acidentes

Durante a tentativa de análise temporal, identificou-se que a coluna `hora` possui severas inconsistências estruturais. Os dados originais apresentam uma mistura de formatos inválidos e até mesmo datas inseridas no lugar de horários (ex: '2024-03-22'). Devido a esse alto nível de corrupção da variável, a extração de insights temporais precisos foi suspensa nesta etapa de diagnóstico e exigirá um tratamento rigoroso (ou descarte) na fase de limpeza da Entrega 2.

3.5 Relações bivariadas e correlações

Buscando entender como as variáveis interagem entre si, foi gerada uma Matriz de Correlação. Notou-se, por exemplo, que o número de motocicletas (`moto`) possui a maior correlação positiva em relação à quantidade de vítimas.

Figura 5: Mapa de calor das correlações numéricas.

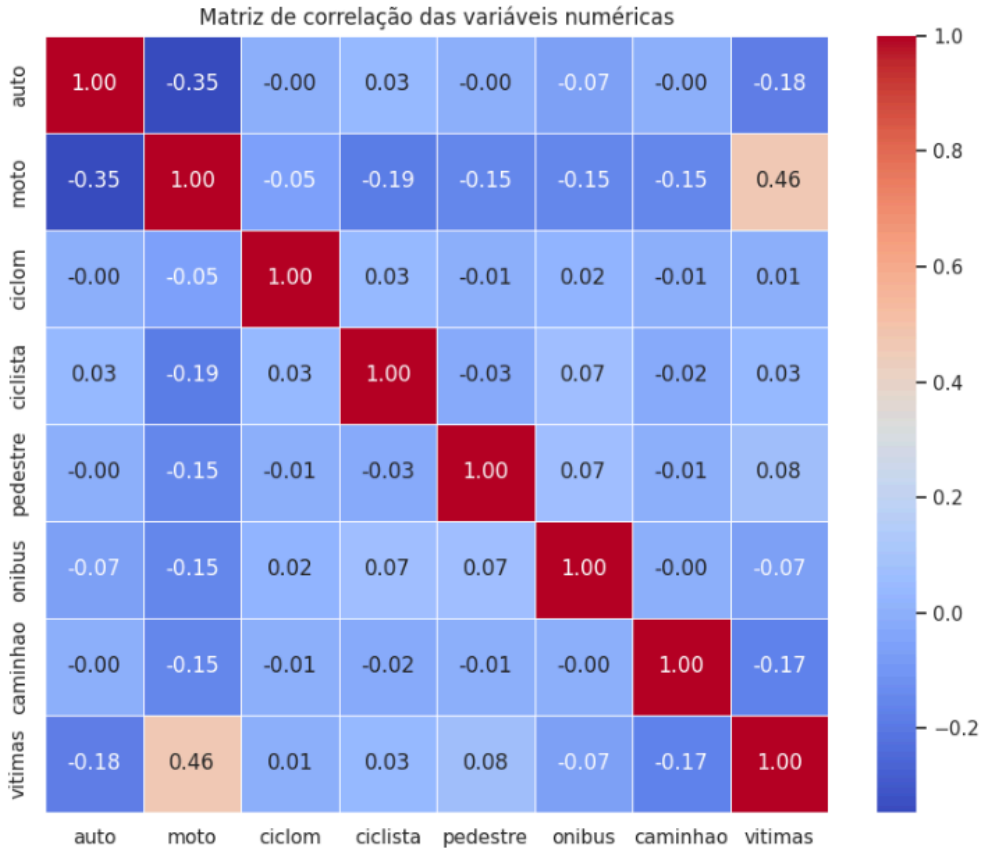

Para confirmar essa relação, o cruzamento entre o envolvimento de motos e a gravidade do acidente demonstrou visualmente que ocorrências envolvendo motocicletas possuem uma tendência altamente concentrada em acidentes "COM VÍTIMA".

Figura 6: Relação entre o número e motos envolvidas e a gravidade final do acidente.

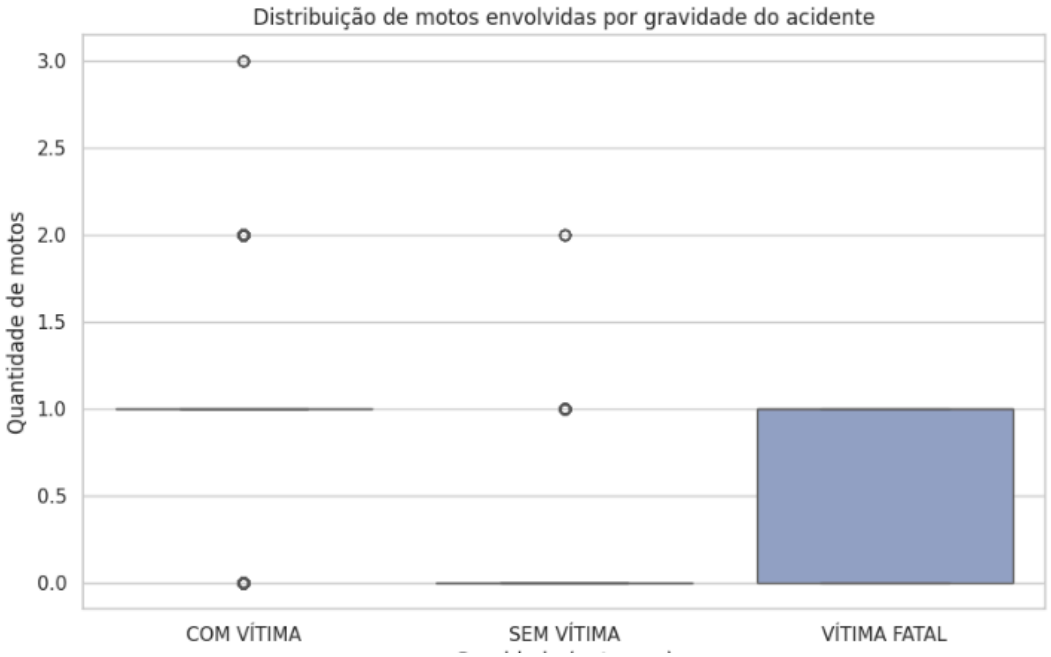

4. Estratégias de tratamento: próximos passos

Com base nos problemas e padrões identificados, foi definido um conjunto de estratégias para a próxima etapa do projeto (Entrega 2), visando preparar os dados para a modelagem com kNN.

4.1 Remoção de variáveis irrelevantes

Serão removidas:

- Colunas com 100% de valores nulos;
- Variáveis com alta taxa de ausência (acima de 80%);
- Identificadores únicos (como Protocolo), que não contribuem para a predição.

4.2 Tratamento da variável alvo

As categorias inconsistentes (APOIO e ENTRADA E SAÍDA) serão removidas ou reclassificadas, mantendo apenas classes que representem efetivamente a gravidade do acidente.

4.3 Conversão e tratamento de variáveis temporais

As colunas `data` e `hora` passarão por uma triagem rigorosa. Serão removidos ou tratados os registros com horários corrompidos e filtradas as datas que fujam do ano de 2024 (ex: 2025). Após a limpeza, as colunas válidas serão convertidas para o formato `datetime`, permitindo a criação de novas variáveis, como período do dia (manhã, tarde, noite, madrugada) e dia da semana.

4.4 Tratamento de outliers

Os valores extremos identificados nas variáveis numéricas serão tratados por meio de remoção de registros absurdos ou pela limitação estatística dos valores (Winsorization

4.5 Preparação para o modelo (encoding e normalização)

As variáveis categóricas serão transformadas em formato numérico utilizando técnicas como One-Hot Encoding ou Label Encoding. Além disso, será aplicada normalização ou padronização nas variáveis numéricas (MinMaxScaler ou StandardScaler), etapa absolutamente essencial para o algoritmo kNN, que utiliza distâncias euclidianas para calcular a similaridade entre os dados.