

Relatório da Entrega 2: Limpeza, Normalização e Encoding

Equipe:

Allanis Beatriz Oliveira Maia de Lima - aboml@cin.ufpe.br

Amanda Pereira Muniz de Oliveira - apmo@cin.ufpe.br

João Victor Alexandre Justino da Silva - jvajs@cin.ufpe.br

Millena Ferreira Marçal das Neves - mfmn@cin.ufpe.br

Nelson de Barros Sales Neto - nbsn@cin.ufpe.br

1. Introdução

Este relatório tem como objetivo analisar como diferentes técnicas de encoding e de normalização (scaling) influenciam o desempenho do algoritmo k-Nearest Neighbors (kNN). Para isso, foi utilizado o conjunto de dados de ocorrências de acidentes de trânsito no Recife em 2024, que reúne informações como localização, tipo de acidente, veículos envolvidos e número de vítimas.

O problema foi tratado como uma tarefa de classificação, em que o modelo kNN busca prever a variável alvo *natureza*, responsável por indicar a gravidade do acidente (por exemplo: "COM VÍTIMA", "SEM VÍTIMA" e "VÍTIMA FATAL").

Na análise exploratória realizada na Entrega 1, foi identificado um forte desbalanceamento entre as classes, além da presença de valores extremos (outliers), principalmente nas variáveis relacionadas à quantidade de veículos e vítimas. Esses fatores reforçam a importância de um bom pré-processamento antes da aplicação do modelo.

2. Pré-processamento e Tratamento de Dados

Antes da aplicação dos modelos, foi realizado um refinamento no conjunto de dados para garantir a qualidade das distâncias calculadas pelo kNN:

- **Limpeza de Colunas:** Foram removidas colunas com alta cardinalidade ou informações irrelevantes para o modelo preditivo, como números de protocolo, endereços detalhados e descrições textuais que não agregariam valor ao cálculo de similaridade por distância.
- **Tratamento de Dados Ausentes:** Para as variáveis categóricas que apresentavam valores nulos, optou-se pela imputação do termo "DESCONHECIDO". Essa estratégia foi escolhida para preservar o tamanho da amostra, evitando o descarte de registros que poderiam conter informações importantes em outras colunas.
- **Tratamento de Outliers:** Identificou-se a presença de valores extremos nas variáveis de contagem (como número de veículos e vítimas). Para essas, aplicou-se a técnica de *clipping* baseada no Intervalo Interquartil (IQR), que limita os valores aos limites inferior e superior, impedindo que registros atípicos distorçam a escala dos dados e prejudiquem o cálculo de distâncias do kNN. Por outro lado, variáveis de geolocalização e tempo (latitude, longitude, data e hora) não passaram por remoção ou capagem de outliers. Optou-se por mantê-las intactas pois valores aparentemente "extremos" nessas features representam, na verdade, ocorrências

reais do trânsito urbano (como acidentes em bairros periféricos ou durante a madrugada) e não erros de medição.

3. Encoding e Scaling

Como o kNN calcula similaridade com base em distâncias, foi necessário transformar os dados para uma representação numérica adequada. As variáveis categóricas escolhidas foram *bairro* e *tipo de acidente*. Para essas colunas, foram testadas três técnicas de encoding:

- **One-hot encoding:** criação de colunas binárias para cada categoria
- **Dummy coding:** semelhante ao one-hot, mas removendo uma coluna para evitar redundância
- **Effect coding (Sum Encoder):** representa cada categoria em relação à média geral

Já para as variáveis numéricas (como número de carros, motos, pedestres e vítimas), foram aplicadas diferentes técnicas de scaling. Isso foi necessário porque essas variáveis apresentaram forte assimetria à direita, com muitos valores baixos e poucos valores muito altos. As técnicas utilizadas foram: Standard Scaler, Min-Max Scaler, Robust Scaler e Quantile Transformer (nas versões uniforme e normal).

Resultados do kNN (k=5)

Abaixo estão apresentadas as tabelas de desempenho para cada combinação. A métrica de F1-Score (Macro) foi incluída, pois a Acurácia isolada pode ser enganosa em dados altamente desbalanceados.

Figura 1: Captura de tela do Google Colab exibindo a tabela geral com os resultados de Acurácia e F1-Score para todas as combinações testadas.

	Dataset	Encoding	Scaling	Acurácia KNN	F1-Score
1	Acidentes Recife 2024	One-hot	Min-Max	0.9122	0.4925
2	Acidentes Recife 2024	One-hot	MaxAbs	0.9122	0.4925
4	Acidentes Recife 2024	One-hot	Quantile (Uniforme)	0.9122	0.4925
13	Acidentes Recife 2024	Effect	Min-Max	0.9122	0.4925
14	Acidentes Recife 2024	Effect	MaxAbs	0.9122	0.4925
16	Acidentes Recife 2024	Effect	Quantile (Uniforme)	0.9122	0.4925
9	Acidentes Recife 2024	Dummy	Robust	0.9116	0.4917
3	Acidentes Recife 2024	One-hot	Robust	0.9097	0.4847
15	Acidentes Recife 2024	Effect	Robust	0.9097	0.4847
7	Acidentes Recife 2024	Dummy	Min-Max	0.9072	0.4899
8	Acidentes Recife 2024	Dummy	MaxAbs	0.9072	0.4899
10	Acidentes Recife 2024	Dummy	Quantile (Uniforme)	0.9072	0.4899
5	Acidentes Recife 2024	One-hot	Quantile (Normal)	0.9072	0.4742
17	Acidentes Recife 2024	Effect	Quantile (Normal)	0.9072	0.4742
11	Acidentes Recife 2024	Dummy	Quantile (Normal)	0.9066	0.4811
0	Acidentes Recife 2024	One-hot	Standard	0.9022	0.4761
12	Acidentes Recife 2024	Effect	Standard	0.9022	0.4761
6	Acidentes Recife 2024	Dummy	Standard	0.9016	0.4802

3. Observações

A análise dos resultados mostrou que o desempenho do kNN varia bastante dependendo das transformações aplicadas nos dados.

Em relação ao scaling, ficou claro que métodos mais sensíveis a outliers, como o Min-Max Scaler, não lidaram bem com a distribuição dos dados. Como existem poucos valores muito altos (por exemplo, acidentes com muitas vítimas), esses métodos acabam comprimindo a maioria dos dados num intervalo muito pequeno. Por outro lado, técnicas mais robustas, como o Robust Scaler e o Quantile Transformer, apresentaram resultados muito melhores. Isso acontece porque elas conseguem reduzir o impacto dos valores extremos e tornar a distribuição mais equilibrada, o que facilita o cálculo de distâncias pelo algoritmo kNN.

Confirmando a nossa hipótese inicial da etapa de EDA (fortíssima assimetria à direita), Os experimentos demonstraram que o modelo kNN obteve seu melhor desempenho de Acurácia (aprox. 91%) utilizando o Quantile Transformer (Normal). No entanto, ao observar o F1-Score (aprox. 0.49), nota-se que o modelo ainda enfrenta dificuldades com o desbalanceamento das classes, um ponto que será o foco da Entrega 4. O uso de Effect Encoding mostrou-se ligeiramente superior ao One-Hot Encoding tradicional por evitar a explosão da dimensionalidade (maldição da dimensionalidade), mantendo a performance do kNN mais estável

Em relação ao encoding, o uso do One-hot encoding aumentou bastante o número de dimensões do dataset, principalmente por causa da variável bairro, que possui muitas categorias. Isso acabou por prejudicar o desempenho do kNN devido à chamada “maldição da dimensionalidade” (onde o cálculo de distâncias perde eficácia em espaços com muitas dimensões vazias). O Dummy coding ajudou a reduzir ligeiramente esse problema ao remover uma coluna, mas a técnica de Effect Encoding demonstrou ser consistentemente superior às abordagens One-hot e Dummy para este conjunto de dados, apresentando o melhor desempenho médio nas previsões da gravidade dos acidentes.

4. Conclusão

Os experimentos realizados mostram que o kNN é bastante sensível à forma como os dados são preparados. Primeiro, ficou evidente que não existe uma única técnica ideal para todos os casos. A escolha do método de scaling precisa considerar a distribuição dos dados, especialmente quando há presença de outliers.

Além disso, o uso exclusivo da acurácia pode levar a interpretações equivocadas, principalmente em cenários com classes desbalanceadas, como neste caso. O F1-Score (macro) se mostrou mais adequado para avaliar o desempenho do modelo, pois considera melhor o equilíbrio entre as classes.

Para ilustrar a discrepância entre a alta Acurácia e o F1-Score mediano, gerou-se a matriz de confusão do melhor modelo kNN (*Figura 4*). Através da matriz, fica visualmente claro que o algoritmo consegue classificar com grande taxa de acerto a classe majoritária das ocorrências, o que eleva a acurácia global. Em contrapartida, o modelo apresenta dificuldades em prever corretamente as classes minoritárias (como vítimas fatais, por exemplo), classificando-as erroneamente. Esse comportamento justifica o F1-Score mais

baixo e comprova a forte presença de desbalanceamento nos dados, problema que será o foco principal de resolução na Entrega 4.

Por fim, os resultados obtidos indicam a importância de técnicas adicionais para lidar com alta dimensionalidade, o que será explorado na próxima etapa com o uso de métodos como PCA.

5. Anexos

Figura 2: Gráfico comparativo de Acurácia entre as combinações de Scaling e Encoding.




Figura 3: Gráfico comparativo de F1-Score (Macro) evidenciando a capacidade do modelo em lidar com as classes desbalanceadas sob diferentes técnicas de pré-processamento.




Figura 4: Matriz de Confusão do modelo *kNN* para a classificação da natureza do acidente.

