

Relatório da Entrega 3: Seleção de Features e Redução de Dimensionalidade

Equipe:

Allanis Beatriz Oliveira Maia de Lima - aboml@cin.ufpe.br

Amanda Pereira Muniz de Oliveira - apmo@cin.ufpe.br

João Victor Alexandre Justino da Silva - jvajs@cin.ufpe.br

Millena Ferreira Marçal das Neves - mfmn@cin.ufpe.br

Nelson de Barros Sales Neto - nbsn@cin.ufpe.br

1. Introdução

O relatório consolida os resultados da Entrega 3 da disciplina, cujo foco é investigar o impacto da Seleção de Features e da Redução de Dimensionalidade na eficácia preditiva do algoritmo KNN. Utilizamos o conjunto de dados de "Ocorrências de Acidentes de Trânsito no Recife (2024)", que apresenta originalmente dezenas de colunas, exigindo pré-processamento para mitigar o viés do algoritmo diante de espaços vetoriais altamente dimensionais. O problema foi configurado como uma tarefa de classificação na qual a variável-alvo é a *natureza* do acidente (Com Vítima, Sem Vítima, Vítima Fatal). O dataset foi previamente higienizado e os dados foram divididos sob proporção 70/30 (preservando o balanceamento via *stratify=y*), culminando na padronização com *StandardScaler* para todas as features preditoras.

2. Metodologia e Resultados

A avaliação explorou quatro frentes para manipulação da dimensionalidade:

1. **Filter Methods:** Uso do *SelectKBest* com teste ANOVA (*f_classif*) para isolar as *k* características de maior variância conjunta com o alvo.
2. **Wrapper Methods:** Uso do *SequentialFeatureSelector* avaliando o modelo de forma iterativa via abordagens *Forward* e *Backward*. É importante ressaltar os desafios computacionais encontrados na aplicação das estratégias Wrapper (*SequentialFeatureSelector*). Devido à alta dimensionalidade do espaço vetorial inicial e à natureza do algoritmo KNN (que exige o cálculo de distâncias para cada predição), o processo de seleção exaustiva apresentou um custo proibitivo, chegando a causar instabilidades no ambiente de execução (erros de Out of Memory). Tal comportamento reforça a literatura da área, que aponta os métodos *Wrapper* como os mais precisos, porém os mais onerosos, exigindo estratégias de otimização como a redução de *folds* na validação cruzada para viabilização técnica.
3. **Embedded Methods:** Uso do *SelectFromModel* acoplado a uma Regressão Logística com penalidade L1 (Lasso), que por natureza "zera" coeficientes de variáveis pouco informativas.
4. **Feature Extraction:** Utilização da Análise de Componentes Principais (PCA) para comprimir a variância dos dados em 2, 3, 5 e 10 componentes.

Figura 1: Comparação do desempenho (Acurácia e F1-Score) do modelo kNN entre o Baseline e as diferentes estratégias de Seleção e Extração de Features.





Figura 2: Comparação da quantidade de features ou componentes principais retidos e utilizados por cada método após as etapas de seleção e extração.



Ao comparar os resultados obtidos, o destaque principal reside na performance do método SelectKBest (Filter) e dos métodos Wrapper. Enquanto o modelo Baseline utilizou a totalidade dos atributos (125 colunas, majoritariamente derivadas do One-Hot Encoding), o SelectKBest operou com apenas 15 atributos e obteve um salto no F1-Score (Macro) de 0,43 para 0,50. Esse fenômeno exemplifica na prática a 'Maldição da Dimensionalidade': ao reduzir o ruído causado por variáveis pouco informativas (como bairros com baixa incidência de acidentes), permitiu-se que o algoritmo KNN calculasse distâncias euclidianas mais precisas entre os pontos, resultando em uma classificação mais robusta da classe 'Sem Vítima'.

Discussão dos Resultados:

Ao observar os cenários testes, notou-se que o modelo **Baseline** atingiu Acurácia de 90% e F1-Score de 43%

A extração por **PCA** revelou-se ineficaz para este conjunto de dados. Como observado no gráfico comparativo, todas as variações testadas (2, 3, 5 e 10 componentes) apresentaram um F1-Score inferior ao do modelo Baseline. Esse comportamento é justificado pela natureza dos dados preditores: por ser um *dataset* dominado por variáveis categóricas transformadas via *One-Hot Encoding* (dados esparsos com muitos zeros), a variância principal capturada pelo PCA não possui forte correlação com as fronteiras de decisão das classes. Consequentemente, a compactação acabou distorcendo o espaço vetorial e prejudicando o cálculo de distâncias do algoritmo KNN.

Entre os métodos de seleção diretos (Filter, Wrapper, Embedded), a técnica **SelectKBest** (Filter) apresentou a melhor combinação de alto desempenho (F1-score de 50%) e enxugamento de dados (custo computacional, reduzindo de 125 para apenas 15 atributos). É importante destacar que o Sequential Feature Selector (Wrapper) se provou muito mais oneroso computacionalmente para treinar, ao passo que o modelo Embedded (L1) ofereceu uma solução rápida e nativa para lidar com as características irrelevantes (como certos bairros que não afetam a gravidade do acidente de forma contundente).

Apesar das melhorias nas métricas globais, observa-se que a classe 'Vítima Fatal' manteve um F1-Score nulo em quase todos os cenários. Este resultado não indica uma falha na seleção de atributos, mas sim o reflexo do desbalanceamento severo do *dataset* original (onde óbitos representam uma fração mínima das amostras). Essa limitação intrínseca dos dados impede que o KNN aprenda padrões para essa classe específica apenas com seleção de variáveis, justificando a necessidade das técnicas de balanceamento (Oversampling/Undersampling) que serão o foco da próxima entrega deste projeto.

4. Conclusão

A partir da atividade empírica, evidenciou-se que a "maldição da dimensionalidade" influencia significativamente as distâncias calculadas pelo KNN. A redução do número de preditores, quando executada por abordagens matemáticas consistentes (como L1 ou PCA com n adequados), conseguiu em alguns casos manter ou superar as métricas do Baseline com uma fração ínfima da dimensionalidade original. A principal lição aprendida é que *mais dados* (mais colunas derivadas de One-Hot Encoding) não é sinônimo de *melhor modelo*; a seleção cautelosa resulta em generalização aprimorada e inferências muito mais leves e rápidas. O desafio residual reside na classe "Vítima Fatal", cujas taxas de F1-Score demonstram um viés devido ao desbalanceamento crônico da amostra, algo que preparamos o terreno para contornar na Entrega 4.

5. Anexos

Em suma, a Entrega 3 demonstrou que, em Ciência de Dados, menos é mais. A capacidade de manter uma acurácia de 91% utilizando apenas 12% da dimensionalidade original (15 de 125 features) prova que a seleção de atributos é essencial para a escalabilidade de modelos baseados em instâncias. O projeto agora segue para a fase de balanceamento, com um conjunto de variáveis já otimizado e livre de ruídos desnecessários.

Figuras 4, 5, 6, 7, 8, 9, 10 e 11: Matrizes de Confusão referentes aos demais cenários de Seleção (Filter, Wrapper Backward, Embedded) e Extração de Atributos (PCA com 2, 3, 5 e 10 componentes).

