

Relatório da Entrega 4:

Equipe:

Allanis Beatriz Oliveira Maia de Lima - aboml@cin.ufpe.br

Amanda Pereira Muniz de Oliveira - apmo@cin.ufpe.br

João Victor Alexandre Justino da Silva - jvajs@cin.ufpe.br

Millena Ferreira Marçal das Neves - mfmn@cin.ufpe.br

Nelson de Barros Sales Neto - nbsn@cin.ufpe.br

1. Introdução

Este relatório documenta a quarta etapa do projeto de Ciência de Dados, cujo objetivo central é tratar o problema de desbalanceamento de classes do conjunto de dados de acidentes de trânsito da cidade do Recife. Além disso, esta entrega consolida as etapas de pré-processamento desenvolvidas nas entregas anteriores (Limpeza, Encoding, Normalização e Seleção de Atributos).

Como visto nas análises preliminares, a variável-alvo natureza apresenta um desbalanceamento severo, onde a classe "COM VÍTIMA" compõe a esmagadora maioria dos registros, enquanto a classe "VÍTIMA FATAL" é extremamente minoritária. O desafio desta etapa é aplicar e avaliar o impacto de diferentes técnicas da biblioteca imblearn (Under-Sampling, Over-Sampling e SMOTE) no poder preditivo do algoritmo k-Nearest Neighbors (kNN).

2. Metodologia: O Pipeline Consolidado

Antes da aplicação das técnicas de balanceamento, foi construído um pipeline definitivo para preparar os dados de forma otimizada. Os dados foram divididos em proporção 70/30 (com o parâmetro stratify=y para manter a distribuição original das classes) e passaram pelo seguinte fluxo:

- **Normalização:** Utilizou-se o StandardScaler nas variáveis numéricas.
- **Encoding:** Aplicou-se o OneHotEncoder nas variáveis categóricas (como os bairros).
- **Seleção de Features (A grande validação da Entrega 3):** Para evitar a "Maldição da Dimensionalidade", que prejudica tanto o kNN quanto a criação de dados sintéticos, aplicamos o método SelectKBest. Isso reduziu o espaço vetorial de 125 colunas esparsas para apenas as **15 features mais relevantes**.

Somente após esta filtragem, os dados de treino foram submetidos às estratégias de balanceamento.

3. Análise Inicial e o Modelo Baseline (Sem Balanceamento)


A análise inicial confirmou a forte discrepância na distribuição das classes. Ao treinar o modelo kNN (com n_neighbors=5) utilizando os dados desbalanceados (Baseline), obtivemos uma Acurácia geral aparentemente alta. Contudo, o relatório de classificação evidenciou a falha do modelo: o F1-Score para a classe "VÍTIMA FATAL" foi de

0.00. O algoritmo simplesmente ignorou a classe minoritária, classificando todos os acidentes graves como pertencentes à classe majoritária.

Resultados do modelo kNN Baseline (sem balanceamento):				
	precision	recall	f1-score	support
COM VÍTIMA	0.92	0.98	0.95	1402
SEM VÍTIMA	0.74	0.43	0.54	183
VÍTIMA FATAL	0.00	0.00	0.00	10
accuracy			0.91	1595
macro avg	0.56	0.47	0.50	1595
weighted avg	0.90	0.91	0.90	1595

A visualização da distribuição original das classes ilustra de forma clara o problema central abordado nesta etapa: o desbalanceamento extremo da variável-alvo natureza. Observa-se que a classe 'COM VÍTIMA' domina o conjunto de dados, representando a esmagadora maioria das ocorrências, seguida pela classe 'SEM VÍTIMA'. Em contrapartida, a classe 'VÍTIMA FATAL' constitui uma fração ínfima do dataset (com apenas 24 instâncias separadas para o conjunto de treino). Esta assimetria severa cria um forte viés preditivo, uma vez que algoritmos baseados em distância, como o kNN, tendem a ignorar os padrões das classes raras em favor da classe majoritária.

Figura 1: Distribuição original das classes da variável-alvo ('natureza'), evidenciando o desbalanceamento severo antes da aplicação de qualquer técnica de amostragem.



4. Aplicação das Técnicas de Balanceamento

Para mitigar o viés do modelo, três abordagens distintas foram aplicadas ao conjunto de treino selecionado:

1. **Random Under-Sampling (RUS):** Reduziu aleatoriamente as instâncias das classes majoritárias para igualá-las à classe minoritária. O conjunto de treino despencou para apenas 24 amostras por classe.
2. **Random Over-Sampling (ROS):** Duplicou aleatoriamente as amostras da classe minoritária ("VÍTIMA FATAL" e "SEM VÍTIMA") até que todas se igualassem ao volume da classe "COM VÍTIMA".
3. **SMOTE (Synthetic Minority Over-sampling Technique):** Em vez de simplesmente duplicar dados, o SMOTE gerou instâncias sintéticas interpolando as características das ocorrências minoritárias existentes, enriquecendo o espaço de dados.

5. Discussão dos Resultados


5.1. Desempenho Preditivo

	Métrica	Baseline	SMOTE	Random Over-Sampling	Random Under-Sampling
0	Acurácia	0.910972	0.910972	0.900940	0.768025
1	F1-Score Macro	0.497522	0.504136	0.497981	0.398252
2	AUC Global	0.710134	0.714663	0.716286	0.695394

A aplicação do balanceamento mudou drasticamente o comportamento do modelo. O modelo treinado com **Under-Sampling** obteve métricas infladas, mas trata-se de um resultado ilusório. Como o algoritmo foi treinado com apenas 72 linhas no total (24 de cada classe), ele perdeu toda a riqueza da variabilidade dos dados urbanos (ruas, horários, tipos de colisão), tornando-se incapaz de generalizar para o mundo real.

Por outro lado, o **SMOTE** e o **Over-Sampling** se destacaram por manterem o volume de dados da classe majoritária enquanto ensinavam o algoritmo a reconhecer os padrões da minoria. O SMOTE permitiu que o modelo finalmente aprendesse a classificar acidentes fatais sem o viés do desbalanceamento original. A visualização das duas primeiras componentes principais (PCA) ilustra claramente como o SMOTE preencheu as regiões de fronteira da classe minoritária.

Figura 2: Comparação do desempenho preditivo (Acurácia e F1-Score Macro) do classificador kNN entre o Baseline e as diferentes técnicas de balanceamento.




A análise detalhada das Matrizes de Confusão permite compreender os mecanismos internos que ditaram a variação das métricas globais em cada estratégia:

- **Cenário (a) Baseline Desbalanceado:** A matriz torna evidente o viés agudo do algoritmo kNN em direção à classe majoritária. Embora o modelo registre um alto volume de acertos para ocorrências 'COM VÍTIMA', ele foi incapaz de classificar corretamente um único caso sequer da classe 'VÍTIMA FATAL' (0 acertos). O algoritmo simplesmente negligenciou a minoria devido à disparidade numérica do espaço amostral.
- **Cenário (b) Random Under-Sampling (RUS):** Embora este método tenha equalizado matematicamente as classes, a matriz revela um colapso na assertividade da classe majoritária 'COM VÍTIMA'. Devido à redução extrema do conjunto de treino para apenas 24 amostras por classe, o kNN perdeu sua capacidade de generalização regional, gerando um número massivo de falsos positivos (classificando acidentes leves erroneamente como fatais ou sem vítima).
- **Cenários (c) Random Over-Sampling (ROS) e (d) SMOTE:** Ambas as abordagens equilibraram o modelo com sucesso. A matriz do SMOTE destaca-se como a solução mais robusta: ela permitiu ao kNN identificar com precisão as ocorrências de 'VÍTIMA FATAL' e expandir consideravelmente os acertos da classe 'SEM VÍTIMA', contendo a dispersão de erros que foi observada no Under-Sampling. Como o

SMOTE interpola vizinhos em vez de apenas duplicar registros (como faz o ROS), ele evitou o overfitting (ajuste excessivo) e estabilizou as fronteiras de decisão do classificador.

Figura 3: Matrizes de Confusão comparativas do classificador kNN sob os quatro cenários: (a) Baseline Desbalanceado, (b) Random Under-Sampling, (c) Random Over-Sampling e (d) SMOTE.




Para além das matrizes de confusão, a capacidade de discriminação dos classificadores foi avaliada através das Curvas ROC e da métrica AUC (Área Sob a Curva) para cada classe, permitindo medir o quão bem o kNN separa as categorias de gravidade dos acidentes:

- **Cenário (a) Baseline Desbalanceado:** Como esperado devido à falta de exemplos, o modelo apresentou uma **AUC de 0.50 para a classe 'VÍTIMA FATAL'**. Matematicamente, uma AUC de 0.50 significa que o modelo tem um desempenho equivalente a um lançamento de moeda ao acaso (aleatório) para identificar acidentes fatais, confirmando a ineficácia do kNN puro perante o desequilíbrio estrutural.
- **Cenário (b) Random Under-Sampling (RUS):** Embora tenha registado valores de AUC elevados nas classes minoritárias, este resultado é severamente distorcido pelo tamanho minúsculo do conjunto de teste equivalente (gerado a partir de apenas 24 amostras de treino). A curva ROC neste cenário sofre de alta variabilidade e não representa um modelo robusto para generalização real.


- **Cenários (c) Random Over-Sampling (ROS) e (d) SMOTE:** Ambos os modelos demonstraram curvas ROC muito mais saudáveis e arqueadas em direção ao topo esquerdo, que é o comportamento ideal de um classificador perfeito. O **SMOTE consolidou-se como o mais equilibrado**, registrando valores de AUC elevados e consistentes para todas as classes. Isto prova que a criação de vizinhos sintéticos expandiu as fronteiras de decisão de forma contínua, permitindo ao kNN manter uma excelente taxa de verdadeiros positivos minimizando os falsos positivos.

Figura 4: Curvas ROC e valores de AUC multiclasse para o classificador kNN: (a) Baseline Desbalanceado, (b) Random Under-Sampling, (c) Random Over-Sampling e (d) SMOTE.



5.2. Custo Computacional

Figura 5: Custo computacional medido em segundos para o treino e predição do modelo kNN sob cada estratégia de amostragem



Ao analisar o custo computacional, observa-se que o método Random Over-Sampling apresentou o maior tempo de execução (aprox. 0.2513s), seguido pelo SMOTE (aprox. 0.2278s). Isso ocorre porque ambas as técnicas aumentam significativamente a quantidade de dados utilizados no treinamento, exigindo mais cálculos de distância pelo algoritmo kNN. O modelo Baseline apresentou um tempo intermediário (aprox. 0.0851s), já que utilizou o conjunto original de dados sem aplicar técnicas de balanceamento. Por outro lado, o método Random Under-Sampling foi o mais rápido (aprox. 0.0167s), devido à redução drástica do conjunto de treinamento para apenas 24 amostras por classe. Apesar da alta velocidade, essa abordagem resultou em perda significativa de informações e pior desempenho do modelo. Dessa forma, os métodos SMOTE e Random Over-Sampling apresentaram o melhor equilíbrio entre desempenho e custo computacional, pois conseguiram balancear as classes mantendo maior quantidade de informação disponível para treinamento.

6. Conclusão

A Entrega 4 evidenciou que métricas como a acurácia, isoladamente, não são suficientes para avaliar modelos aplicados a conjuntos de dados desbalanceados no contexto de acidentes de trânsito. A consolidação do pipeline, combinando redução de dimensionalidade com SelectKBest e técnicas de balanceamento, permitiu uma análise mais robusta do desempenho do kNN.

Entre as abordagens avaliadas, o SMOTE apresentou o melhor equilíbrio entre desempenho preditivo e custo computacional, melhorando a representatividade das classes minoritárias sem perda significativa de informação. Já o Random Under-Sampling, apesar de reduzir o tempo de execução, comprometeu o desempenho do modelo devido à remoção excessiva de dados relevantes.

Embora a classe "VÍTIMA FATAL" ainda tenha apresentado dificuldade de identificação, os resultados demonstraram avanços importantes no tratamento do desbalanceamento e na construção de um pipeline mais consistente para as próximas etapas do projeto.

7. Anexos: Relatórios de Classificação

Relatório de classificação detalhado gerado através do balanceamento por SMOTE. Esta abordagem consolidou o melhor equilíbrio preditivo entre todas as técnicas avaliadas, expandindo de forma robusta as taxas de precisão e recall das classes minoritárias através da criação de instâncias sintéticas por interpolação de vizinhos próximos:

```
Distribuição das classes antes do balanceamento:
natureza
COM VÍTIMA      3269
SEM VÍTIMA      427
VÍTIMA FATAL    24
Name: count, dtype: int64
```

```
Distribuição das classes após o SMOTE:
natureza
COM VÍTIMA      3269
SEM VÍTIMA      3269
VÍTIMA FATAL    3269
Name: count, dtype: int64
```

```
Resultados do modelo kNN após balanceamento (SMOTE):
              precision    recall  f1-score   support

   COM VÍTIMA      0.93      0.98      0.95      1402
   SEM VÍTIMA      0.75      0.45      0.56       183
  VÍTIMA FATAL      0.00      0.00      0.00        10

   accuracy              0.91      1595
  macro avg              0.56      1595
 weighted avg              0.90      1595
```

Abaixo é apresentado o relatório de classificação após a aplicação do método Random Over-Sampling (ROS). A técnica apresentou melhor equilíbrio entre as classes em relação ao modelo baseline, principalmente para a classe “SEM VÍTIMA”, que obteve melhora no recall e manteve um F1-score semelhante ao SMOTE. Entretanto, a classe “VÍTIMA FATAL” continuou sem ser corretamente identificada, devido à baixa quantidade de exemplos disponíveis para treinamento. Ainda assim, o método manteve boa acurácia geral (~90%) e desempenho satisfatório no balanceamento das classes sem perda significativa de informação.

Distribuição das classes antes do balanceamento:

```
natureza
COM VÍTIMA      3269
SEM VÍTIMA      427
VÍTIMA FATAL    24
Name: count, dtype: int64
```

Distribuição das classes após o Random Over-Sampling:

```
natureza
COM VÍTIMA      3269
SEM VÍTIMA      3269
VÍTIMA FATAL    3269
Name: count, dtype: int64
```

Random Over-Sampling - Classification Report:

	precision	recall	f1-score	support
COM VÍTIMA	0.93	0.96	0.95	1402
SEM VÍTIMA	0.65	0.48	0.55	183
VÍTIMA FATAL	0.00	0.00	0.00	10
accuracy			0.90	1595
macro avg	0.53	0.48	0.50	1595
weighted avg	0.89	0.90	0.89	1595

AUC Global com Random Over-Sampling (OvR): 0.7163

O método Random Under-Sampling reduziu todas as classes para apenas 24 amostras, igualando a quantidade de registros da menor classe ("VÍTIMA FATAL"). Apesar de diminuir bastante o custo computacional, essa abordagem causou grande perda de informação, prejudicando o aprendizado do modelo. Como resultado, houve queda na acurácia geral (~77%) e no F1-score macro (~0.40), indicando desempenho inferior em comparação às demais técnicas. Embora tenha ocorrido pequena melhora no recall da classe "SEM VÍTIMA", o modelo continuou sem identificar corretamente a classe "VÍTIMA FATAL".

Distribuição das classes após Undersampling:

```
natureza
COM VÍTIMA      24
SEM VÍTIMA      24
VÍTIMA FATAL    24
Name: count, dtype: int64
```

Resultados do modelo kNN após balanceamento (Undersampling):

	precision	recall	f1-score	support
COM VÍTIMA	0.92	0.82	0.87	1402
SEM VÍTIMA	0.27	0.42	0.33	183
VÍTIMA FATAL	0.00	0.00	0.00	10
accuracy			0.77	1595
macro avg	0.40	0.41	0.40	1595
weighted avg	0.84	0.77	0.80	1595

AUC Global com Random Under-Sampling (OvR): 0.6954