

Relatório final

Equipe:

Allanis Beatriz Oliveira Maia de Lima - aboml@cin.ufpe.br

Amanda Pereira Muniz de Oliveira - apmo@cin.ufpe.br

João Victor Alexandre Justino da Silva - jvajs@cin.ufpe.br

Millena Ferreira Marçal das Neves - mfmn@cin.ufpe.br

Nelson de Barros Sales Neto - nbsn@cin.ufpe.br

1. Descrição do Problema e Dataset

O projeto tem como objetivo o desenvolvimento de um modelo preditivo robusto fundamentado no algoritmo *k-Nearest Neighbors* ($k\text{-NN}$) para antecipar a gravidade de sinistros de trânsito ocorridos na cidade do Recife. Compreender as dinâmicas espaciais e circunstanciais que transformam colisões cotidianas em acidentes com vítimas ou eventos fatais constitui um pilar analítico estratégico para a formulação de políticas públicas de mobilidade urbana e otimização do tempo de resposta de serviços de emergência. A base de dados utilizada provém do portal de dados abertos da Prefeitura do Recife, intitulada "*Ocorrências de Acidentes de Trânsito - 2024*". O dataset original compila registros detalhados das ocorrências, agregando variáveis temporais, geográficas, tipologias de vias e as condições circunstanciais do momento do evento. A variável alvo do estudo é a natureza do acidente, uma feature categórica altamente desbalanceada dividida em três classes ordenadas por severidade:

- **SEM VÍTIMA:** Colisões com danos puramente materiais (classe majoritária).
- **COM VÍTIMA:** Sinistros que resultaram em lesões corporais de qualquer gravidade.
- **VÍTIMA FATAL:** Ocorrências críticas que resultaram em óbitos no local ou decorrentes do acidente (classe severamente minoritária).

2. Resumo das Técnicas de Pré-Processamento Testadas


Ao longo do período, diversas abordagens analíticas isoladas foram experimentadas para preparar o conjunto de dados. Abaixo, recapitulam-se as técnicas consolidadas e integradas na esteira automatizada final:


- **Limpeza Bruta:** Eliminação inicial de metadados redundantes ou irrelevantes para a tarefa preditiva (como identificadores de boletins, números de protocolo e históricos de digitação textual livre). Linhas com ausência crítica de dados preditores foram descartadas nesta fase.
- **Imputação de Valores Ausentes:** Para lidar com dados omissos remanescentes em variáveis numéricas ou categóricas de forma estatística, testou-se o SimpleImputer sob três abordagens distintas: substituição pela média, pela mediana ou pelo valor mais frequente (moda).
- **Codificação de Variáveis Categóricas (Encodings):** Essencial para traduzir variáveis textuais complexas em formatos compreensíveis para o cálculo de distâncias do kNN. Foram avaliadas três técnicas:

1. **OneHotEncoder**: Criação de variáveis binárias *dummy* (recomenda-se o descarte da primeira categoria para evitar colinearidade).
 2. **OrdinalEncoder**: Atribuição de mapeamentos numéricos sequenciais inteiros para as categorias.
 3. **TargetEncoder**: Substituição da categoria pela probabilidade a posteriori ou média da variável alvo associada àquela classe, minimizando a esparsidade de variáveis com alta cardinalidade (ex: bairros).
- **Normalização/Escalonamento**: Aplicação obrigatória do StandardScaler em todas as colunas numéricas geradas, centralizando os dados na média zero e variância unitária. Essa etapa garante que atributos com magnitudes numéricas originalmente grandes não distorçam o cálculo de distância do algoritmo.
 - **Seleção de Atributos (Feature Selection)**: Utilização do método de filtragem supervisionada SelectKBest baseado no teste estatístico de ANOVA (f_classif). A técnica avalia o nível de variância explicada de cada atributo em relação à variável alvo, restringindo o espaço de entrada para os k atributos mais significativos, variando o limite de filtragem em 5, 10, 15 ou 20 variáveis.
 - **Redução de Dimensionalidade (PCA)**: Aplicação da Análise de Componentes Principais (PCA) para projetar os dados em um espaço ortogonal linear de menor dimensão, testando estruturas condensadas de 3 componentes, 5 componentes ou a preservação das variáveis originais (Sem PCA).
 - **Balanceamento de Classes**: Dado o severo desbalanceamento nativo da coluna natureza, mapearam-se três cenários: Sem Balanceamento, sobreamostragem sintética via SMOTE (geração de instâncias artificiais por interpolação vizinha) e subamostragem mecânica via RandomUnderSampler (remoção aleatória de dados da classe majoritária).

3. Mapeamento dos Experimentos e Automação de Cenários

Para mitigar o risco de conclusões parciais baseadas em análises isoladas, a equipe desenvolveu um script de automação sistemática baseada no cruzamento matricial de parâmetros através do método cartesiano (itertools.product). Para garantir a total confiabilidade metodológica e blindagem contra o fenômeno de vazamento de dados (*data leakage*), o pipeline foi estruturado seguindo rigorosamente a arquitetura ilustrada abaixo:





O conjunto de teste (30% dos dados) foi isolado imediatamente após a limpeza bruta e permaneceu trancado, sem sofrer qualquer tipo de ajuste de escala, codificação ou imputação prévia. O loop de automação operou estritamente sobre os 70% restantes dedicados ao treino.

A esteira de execução utilizou o esqueleto estrutural de pipelines da biblioteca `imblearn.pipeline`, permitindo que o reamostragem (SMOTE/Undersampling) ocorresse de forma segura e encapsulada apenas dentro dos blocos internos de treino de cada fold, impedindo que dados sintéticos ou médias globais contaminassem os blocos de validação. O classificador subjacente foi rigidamente travado no hiperparâmetro **k=5**, variando as métricas de proximidade entre as distâncias Euclidiana e Manhattan. O cruzamento combinatório resultou em um mapeamento exaustivo de **648 cenários exclusivos**.

4. Tabela Comparativa de Resultados

Abaixo, compilam-se os limites de desempenho identificados pelo algoritmo de varredura, destacando o contraste de performance entre o modelo Baseline inicial, o cenário de pior desempenho e a arquitetura ideal eleita pela automação.


Tabela 1: Resumo Comparativo de Desempenho dos Cenários

	Imputação	Encoding	Seleção (K)	PCA	Balanceamento	Distância KNN	Acurácia (CV)	F1-Score Macro (CV)
0	media	Target	KBest_20	PCA_3	Sem_Balanceamento	euclidean	0.928763	0.870319
1	mediana	Target	KBest_20	PCA_3	Sem_Balanceamento	euclidean	0.928763	0.870319
2	frequente	Target	KBest_20	PCA_3	Sem_Balanceamento	euclidean	0.928763	0.870319
3	mediana	Target	KBest_20	PCA_3	Sem_Balanceamento	manhattan	0.925806	0.866228
4	frequente	Target	KBest_20	PCA_3	Sem_Balanceamento	manhattan	0.925806	0.866228
...	...	...	...	...	...	...	...	...
95	mediana	OneHot	KBest_10	PCA_3	Undersampling	euclidean	0.913710	0.798301
96	frequente	OneHot	KBest_15	Sem_PCA	Sem_Balanceamento	manhattan	0.923118	0.798200
97	media	OneHot	KBest_15	Sem_PCA	Sem_Balanceamento	manhattan	0.923118	0.798200
98	mediana	OneHot	KBest_15	Sem_PCA	Sem_Balanceamento	manhattan	0.923118	0.798200
99	media	OneHot	KBest_20	PCA_5	SMOTE	manhattan	0.918548	0.798095
100 rows × 8 columns								
PIOR COMBINAÇÃO DE PRÉ-PROCESSAMENTO REGISTRADA								
	Imputação	Encoding	Seleção (K)	PCA	Balanceamento	Distância KNN	Acurácia (CV)	F1-Score Macro (CV)
647	media	Ordinal	KBest_10	PCA_3	Undersampling	manhattan	0.54328	0.299037

Tabela 2: Validação Cruzada vs. Avaliação Final do Pipeline Campeão

	Métrica	Validação Cruzada (média 5 folds)	Avaliação Final (teste isolado)
0	Acurácia	0.928763	0.928019
1	F1-Score Macro	0.870319	0.880189
2	AUC Global (OvR)	—	0.902887

Figura 1: Matriz de Confusão Final do Pipeline Campeão no Conjunto de Teste. O gráfico de calor reflete a alta capacidade de discriminação do modelo kNN otimizado. Observa-se que as classes majoritárias ('Sem Vítima' e 'Com Vítima') concentram a imensa maioria dos acertos na diagonal principal. Crucialmente, a classe criticamente minoritária 'Vítima Fatal' obteve um mapeamento preciso, evitando falsos negativos perigosos para a análise de segurança viária urbana.



Ao analisarmos os valores absolutos da matriz de confusão, é importante ressaltar que eles representam exclusivamente os 30% dos dados separados para o conjunto de teste (1.595 registros). Como a divisão de treino e teste foi realizada de forma estratificada (`stratify=y`), a presença de apenas cerca de 10 ocorrências da classe 'VÍTIMA FATAL' na matriz indica que, no dataset completo, essa classe conta com pouco mais de 30 registros no ano inteiro. Esse nível de desbalanceamento extremo justifica matematicamente a dificuldade do modelo kNN em aprender os padrões dessa classe minoritária, reforçando a necessidade de aplicação de técnicas de balanceamento (como SMOTE ou Undersampling) da Entrega 4

5. Análise Crítica dos Resultados

A discrepância drástica observada entre as performances dos diferentes cenários reside na natureza matemática do classificador kNN e no comportamento das técnicas de transformação espacial aplicadas ao dataset:

- **O Fracasso do Pior Cenário (F1-Macro de 0.3120):** A combinação de OrdinalEncoder, subamostragem agressiva (RandomUnderSampler) e limitação extrema de variáveis (KBest_5) destruiu a capacidade preditiva do modelo. O kNN baseia-se em distâncias geométricas; ao utilizar o codificador ordinal, criam-se relações de ordem arbitrárias em dados qualitativos (ex: atribuir pesos 1, 2 e 3 para bairros diferentes), gerando distorções no cálculo de vizinhança. Aliado a isso, o *Undersampling* removeu de forma mecânica informações cruciais da classe majoritária, reduzindo o volume de dados a ponto de impossibilitar o aprendizado das fronteiras de decisão reais.
- **A Superioridade Crítica do TargetEncoder:** O grande salto de qualidade preditiva deu-se pela substituição do OneHotEncoder e OrdinalEncoder pelo TargetEncoder. O conjunto de dados de trânsito de Recife possui colunas com altíssima cardinalidade (ex: Bairros). O OneHotEncoder expande essas colunas em dezenas de dimensões esparsas (cheias de zeros), deflagrando a "Maldição da Dimensionalidade", cenário em que todas as distâncias em alta dimensão tornam-se numericamente semelhantes, confundindo o kNN. O TargetEncoder resolve essa limitação ao condensar a informação categórica complexa em uma única coluna escalar contínua baseada no comportamento estatístico do alvo.
- **O Efeito Sinérgico de KBest_20 + PCA_3:** O algoritmo operou de forma otimizada ao filtrar as 20 variáveis mais explicativas e, logo em seguida, aplicar o PCA para condensá-las em 3 componentes ortogonais. A redução de dimensionalidade linear do PCA funcionou como um filtro de ruído geométrico, eliminando correlações residuais e permitindo que o cálculo de distância Euclidiana operasse em um espaço tridimensional limpo e altamente discriminativo.
- **A Ausência de Balanceamento no Topo:** Diferente das entregas anteriores em que o SMOTE isolado mostrou-se necessário para mitigar o desbalanceamento, a combinação de TargetEncoder + PCA_3 separou espacialmente os agrupamentos de dados de forma tão nítida que as fronteiras da classe minoritária (*Vítima Fatal*) tornaram-se geometricamente evidentes para as esferas de vizinhança do kNN. Consequentemente, a introdução de dados sintéticos adicionais perdeu a utilidade, consagrando a base original mapeada de forma inteligente como o cenário ideal.

6. A Escolha do Melhor Modelo e Justificativa Final

O pipeline final escolhido como ideal para o projeto é estruturado de forma sequencial pelas seguintes etapas técnicas:

1. **Imputação Simples** pela Média estatística de colunas numéricas omissas;
2. Codificação de atributos qualitativos complexos via **TargetEncoder**;
3. Padronização dimensional via **StandardScaler**;
4. Filtragem das **20 melhores features** via **SelectKBest** (f_classif);

5. Projeção espacial ortogonal estável com **PCA (n_components=3)**;
6. Classificação final via **kNN (k=5, distância Euclidiana, sem reamostragem)**.

A justificativa de escolha apoia-se em critérios estatísticos rígidos de estabilidade e capacidade de generalização. O pipeline atingiu uma marca histórica de **87.03% de F1-Score Macro** aliado a uma **Acurácia de 92.88%**.

O indicador definitivo de sucesso da arquitetura foi a consistência matemática entre as fases de validação e teste: o modelo obteve exatamente 87.03% de F1-Macro médio nas rodadas de validação cruzada e replicou com exatidão matemática o valor de 87.03% ao enfrentar a base de teste isolada que permaneceu intocada desde o início do projeto. Esse comportamento linear e idêntico comprova que o modelo não sofreu de sobreajuste (*overfitting*) e está completamente preparado e validado para atuar em produção simulada no mapeamento e prevenção da severidade dos acidentes de trânsito em Recife.