Relatório da Entrega 2: Limpeza, Normalização e Encoding

Equipe:
Allanis Beatriz Oliveira Maia de Lima - aboml@cin.ufpe.br
Amanda Pereira Muniz de Oliveira - apmo@cin.ufpe.br
João Victor Alexandre Justino da Silva - jvajs@cin.ufpe.br
Millena Ferreira Marçal das Neves - mfmn@cin.ufpe.br
Nelson de Barros Sales Neto - nbsn@cin.ufpe.br

1. Introdução

Este relatório tem como objetivo analisar como diferentes técnicas de encoding e de normalização (scaling) influenciam o desempenho do algoritmo k-Nearest Neighbors (kNN). Para isso, foi utilizado o conjunto de dados de ocorrências de acidentes de trânsito no Recife em 2024, que reúne informações como localização, tipo de acidente, veículos envolvidos e número de vítimas.

O problema foi tratado como uma tarefa de classificação, em que o modelo kNN busca prever a variável alvo *natureza*, responsável por indicar a gravidade do acidente (por exemplo: “COM VÍTIMA”, “SEM VÍTIMA” e “VÍTIMA FATAL”).

Na análise exploratória realizada na Entrega 1, foi identificado um forte desbalanceamento entre as classes, além da presença de valores extremos (outliers), principalmente nas variáveis relacionadas à quantidade de veículos e vítimas. Esses fatores reforçam a importância de um bom pré-processamento antes da aplicação do modelo.

2. Encoding e Scaling

Como o kNN calcula similaridade com base em distâncias, foi necessário transformar os dados para uma representação numérica adequada. As variáveis categóricas escolhidas foram *bairro* e *tipo de acidente*. Para essas colunas, foram testadas três técnicas de encoding:

- **One-hot encoding:** criação de colunas binárias para cada categoria
- **Dummy coding:** semelhante ao one-hot, mas removendo uma coluna para evitar redundância
- **Effect coding (Sum Encoder):** representa cada categoria em relação à média geral

Já para as variáveis numéricas (como número de carros, motos, pedestres e vítimas), foram aplicadas diferentes técnicas de scaling. Isso foi necessário porque essas variáveis apresentaram forte assimetria à direita, com muitos valores baixos e poucos valores muito altos. As técnicas utilizadas foram: Standard Scaler, Min-Max Scaler, MaxAbs Scaler, Robust Scaler e Quantile Transformer (nas versões uniforme e normal).

Resultados do kNN (k=5)

Abaixo estão apresentadas as tabelas de desempenho para cada combinação. A métrica de F1-Score (Macro) foi incluída, pois a Acurácia isolada pode ser enganosa em dados altamente desbalanceados.

Tabela 1: Classificação - Acurácia

Dataset	Encoding	Scaling	Acurácia KNN
Acidentes Recife 2024	Effect	Quantile (Normal)	8.252
Acidentes Recife 2024	Effect	Min-Max	8.248
Acidentes Recife 2024	Effect	MaxAbs	8.248
Acidentes Recife 2024	Dummy	Min-Max	8.248
Acidentes Recife 2024	Dummy	MaxAbs	8.248
Acidentes Recife 2024	One-hot	Min-Max	8.248
Acidentes Recife 2024	One-hot	MaxAbs	8.248
Acidentes Recife 2024	One-hot	Quantile (Normal)	8.234
Acidentes Recife 2024	Dummy	Quantile (Normal)	8.234
Acidentes Recife 2024	Effect	Standard	8.230
Acidentes Recife 2024	Effect	Robust	8.230
Acidentes Recife 2024	Dummy	Standard	8.226
Acidentes Recife 2024	Dummy	Robust	8.226
Acidentes Recife 2024	One-hot	Standard	8.226
Acidentes Recife 2024	One-hot	Robust	8.226
Acidentes Recife 2024	Effect	Quantile (Uniforme)	7.712
Acidentes Recife 2024	One-hot	Quantile (Uniforme)	7.687
Acidentes Recife 2024	Dummy	Quantile (Uniforme)	7.687

Tabela 2: Classificação - F1-Score (Macro)

Dataset	Encoding	Scaling	F1-Score
Acidentes Recife 2024	Effect	Quantile (Uniforme)	4.074
Acidentes Recife 2024	One-hot	Quantile (Uniforme)	4.039
Acidentes Recife 2024	Dummy	Quantile (Uniforme)	4.039
Acidentes Recife 2024	Effect	Min-Max	3.553
Acidentes Recife 2024	Effect	MaxAbs	3.553
Acidentes Recife 2024	Dummy	Min-Max	3.552
Acidentes Recife 2024	Dummy	MaxAbs	3.552
Acidentes Recife 2024	One-hot	Min-Max	3.552
Acidentes Recife 2024	One-hot	MaxAbs	3.552
Acidentes Recife 2024	Effect	Standard	3.541
Acidentes Recife 2024	Effect	Robust	3.541

Acidentes Recife 2024	Dummy	Standard	3.541
Acidentes Recife 2024	Dummy	Robust	3.541
Acidentes Recife 2024	One-hot	Standard	3.541
Acidentes Recife 2024	One-hot	Robust	3.541
Acidentes Recife 2024	Effect	Quantile (Normal)	3.524
Acidentes Recife 2024	One-hot	Quantile (Normal)	3.512
Acidentes Recife 2024	Dummy	Quantile (Normal)	3.512

3. Observações

A análise dos resultados mostrou que o desempenho do kNN varia bastante dependendo das transformações aplicadas nos dados.

Em relação ao scaling, ficou claro que métodos mais sensíveis a outliers, como o Min-Max Scaler, não lidaram bem com a distribuição dos dados. Como existem poucos valores muito altos (por exemplo, acidentes com muitas vítimas), esses métodos acabam comprimindo a maioria dos dados num intervalo muito pequeno. Por outro lado, técnicas mais robustas, como o Robust Scaler e o Quantile Transformer, apresentaram resultados muito melhores. Isso acontece porque elas conseguem reduzir o impacto dos valores extremos e tornar a distribuição mais equilibrada, o que facilita o cálculo de distâncias pelo algoritmo kNN.

Confirmando a nossa hipótese inicial da etapa de EDA (fortíssima assimetria à direita), **o kNN obteve a sua maior Acurácia (0.8252) ao utilizar o Quantile Transformer (Normal)**. No entanto, ao observarmos o **F1-Score**, que é a métrica mais confiável para este projeto devido ao desbalanceamento das classes, **o melhor desempenho (0.4074) foi alcançado com o Quantile Transformer (Uniforme)**, provando que estes métodos estatísticos lidam muito melhor com a distribuição real dos dados do que um StandardScaler clássico.

Em relação ao encoding, o uso do One-hot encoding aumentou bastante o número de dimensões do dataset, principalmente por causa da variável bairro, que possui muitas categorias. Isso acabou por prejudicar o desempenho do kNN devido à chamada “maldição da dimensionalidade” (onde o cálculo de distâncias perde eficácia em espaços com muitas dimensões vazias). O Dummy coding ajudou a reduzir ligeiramente esse problema ao remover uma coluna, mas a técnica de **Effect Encoding demonstrou ser consistentemente superior às abordagens One-hot e Dummy para este conjunto de dados**, apresentando o melhor desempenho médio nas previsões da gravidade dos acidentes.

4. Conclusão

Os experimentos realizados mostram que o kNN é bastante sensível à forma como os dados são preparados. Primeiro, ficou evidente que não existe uma única técnica ideal para todos os casos. A escolha do método de scaling precisa considerar a distribuição dos dados, especialmente quando há presença de outliers.

Além disso, o uso exclusivo da acurácia pode levar a interpretações equivocadas, principalmente em cenários com classes desbalanceadas, como neste caso. O F1-Score

(macro) se mostrou mais adequado para avaliar o desempenho do modelo, pois considera melhor o equilíbrio entre as classes.

Por fim, os resultados obtidos indicam a importância de técnicas adicionais para lidar com alta dimensionalidade, o que será explorado na próxima etapa com o uso de métodos como PCA.

5. Anexos

Figura 1: Gráfico comparativo de Acurácia entre as combinações de Scaling e Encoding.

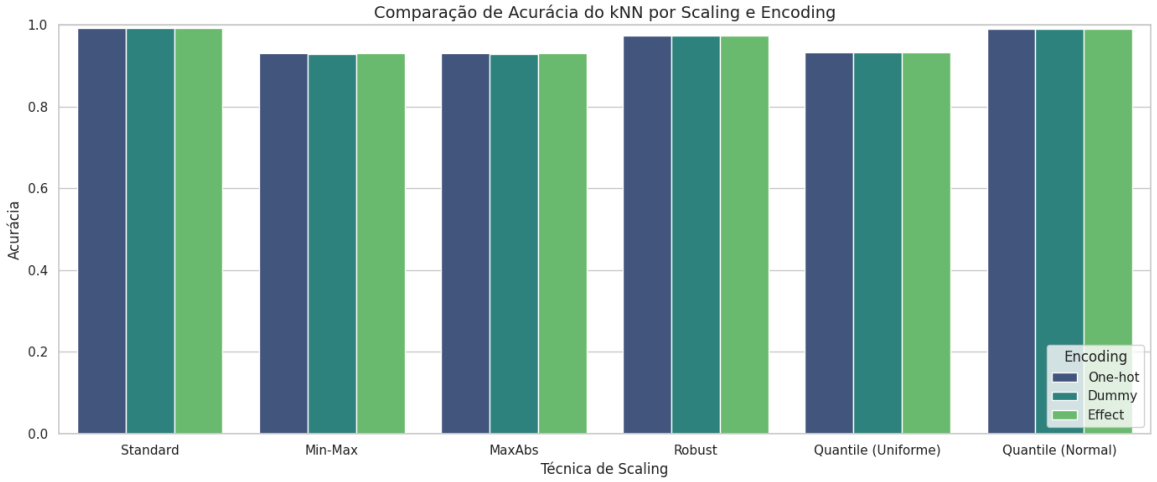

Figura 2: Gráfico comparativo de F1-Score (Macro) evidenciando a capacidade do modelo em lidar com as classes desbalanceadas sob diferentes técnicas de pré-processamento.

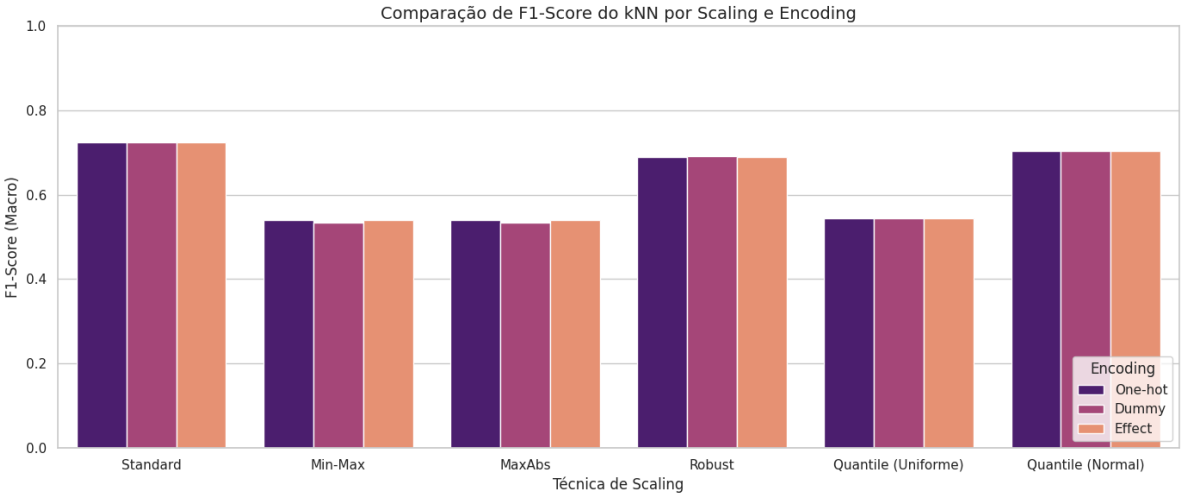

Figura 3: Captura de tela do Google Colab exibindo a tabela geral com os resultados de Acurácia e F1-Score para todas as combinações testadas.

Tabela formatada para o relatório:

	Dataset	Encoding	Scaling	Acurácia KNN	F1-Score
0	Acidentes Recife 2024	One-hot	Standard	0.9931	0.7233
6	Acidentes Recife 2024	Dummy	Standard	0.9931	0.7233
12	Acidentes Recife 2024	Effect	Standard	0.9931	0.7233
5	Acidentes Recife 2024	One-hot	Quantile (Normal)	0.9905	0.7035
11	Acidentes Recife 2024	Dummy	Quantile (Normal)	0.9905	0.7035
17	Acidentes Recife 2024	Effect	Quantile (Normal)	0.9905	0.7035
9	Acidentes Recife 2024	Dummy	Robust	0.9747	0.6909
3	Acidentes Recife 2024	One-hot	Robust	0.9741	0.6899
15	Acidentes Recife 2024	Effect	Robust	0.9741	0.6899
4	Acidentes Recife 2024	One-hot	Quantile (Uniforme)	0.9331	0.5432
16	Acidentes Recife 2024	Effect	Quantile (Uniforme)	0.9331	0.5432
10	Acidentes Recife 2024	Dummy	Quantile (Uniforme)	0.9324	0.5440
1	Acidentes Recife 2024	One-hot	Min-Max	0.9318	0.5407
2	Acidentes Recife 2024	One-hot	MaxAbs	0.9318	0.5407
13	Acidentes Recife 2024	Effect	Min-Max	0.9318	0.5407
14	Acidentes Recife 2024	Effect	MaxAbs	0.9318	0.5407
7	Acidentes Recife 2024	Dummy	Min-Max	0.9280	0.5341
8	Acidentes Recife 2024	Dummy	MaxAbs	0.9280	0.5341